

TEA040 Otimização de parâmetros 2026-2

– Notas de aula

Nelson Luís Dias

Prof. Titular, Departamento de Engenharia Ambiental, UFPR

24 de setembro de 2026

Sumário

1	Mínimos quadrados, função afim	3
2	A regressão $y = ax$	7
3	Erros dos parâmetros de $y = ax + b$	10
4	Matrizes e concavidade	15
4.1	Transformações definidas e indefinidas	15
4.2	Máximos e mínimos de funções de mais de uma variável .	16
4.3	Multiplicadores de Lagrange	19
5	steep: Steepest descent method for nonlinear least squares	22
5.1	Before Gavin	22
5.2	Adapting to find the best parameter set θ	25
5.3	After Gavin	29
6	gnewton: Gauss-Newton (cleaner)	32
7	levmar: Levenberg-Marquardt	34

Capítulo 1

Mínimos quadrados, função afim

A equação que equaciona tudo é açafão

Talvez o método de otimização mais conhecido seja a obtenção por mínimos quadrados dos parâmetros a e b da equação da reta,

$$y = ax + b \quad (1.1)$$

através de um conjunto de pontos (x_i, y_i) , $i = 1, \dots, n$. Em geral, os pontos observados, ou medidos, apresentam uma certa dispersão, e não se ajustam perfeitamente ao modelo adotado (no caso, a reta (1.1)). A figura 1.1 mostra uma comparação de dados da temperatura média da superfície da água medida em uma bóia (Sentinel, lago Mead, EUA) e a temperatura média da superfície estimada por sensoriamento remoto (MODIS).

Construa uma função objetivo

$$F(a, b; \mathbf{x}, \mathbf{y}) = \frac{1}{n} \sum_{i=1}^n [(ax_i + b) - y_i]^2, \quad (1.2)$$

e force (a, b) a ser um ponto extremo:

$$\frac{\partial F}{\partial a} = 0, \quad (1.3)$$

$$\frac{\partial F}{\partial b} = 0. \quad (1.4)$$

A 1ª equação acima produz

$$\begin{aligned} \frac{2}{n} \sum_{i=1}^n [(ax_i + b) - y_i] x_i &= 0, \\ a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i &= \sum_{i=1}^n x_i y_i. \end{aligned} \quad (1.5)$$

A 2ª equação produz

$$\begin{aligned} \frac{2}{n} \sum_{i=1}^n [(ax_i + b) - y_i] &= 0, \\ a \sum_{i=1}^n x_i + nb &= \sum_{i=1}^n y_i. \end{aligned} \quad (1.6)$$




Figura 1.1: Comparação de dados medidos em uma bóia com dados medidos por sensoriamento remoto, lago Mead, EUA.

Temos portanto um sistema 2×2 ,

$$\begin{bmatrix} \sum x_i & n \\ \sum x_i^2 & \sum x_i \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix} \quad (1.7)$$

cujas soluções são

$$a = \frac{(\sum x_i)(\sum y_i) - n \sum x_i y_i}{(\sum x_i)^2 - n \sum x_i^2},$$

$$b = \frac{(\sum x_i)(\sum x_i y_i) - (\sum x_i^2)(\sum y_i)}{(\sum x_i)^2 - n \sum x_i^2}.$$

O denominador das duas equações acima é negativo, e é preferível escrever

$$a = \frac{n \sum x_i y_i - (\sum x_i)(\sum y_i)}{n \sum x_i^2 - (\sum x_i)^2}, \quad (1.8)$$

$$b = \frac{(\sum x_i^2)(\sum y_i) - (\sum x_i)(\sum x_i y_i)}{n \sum x_i^2 - (\sum x_i)^2}. \quad (1.9)$$

Embora (1.8)–(1.9) sejam frequentemente apresentadas nesta forma, existe uma alternativa preferível tanto analiticamente quanto computacionalmente. Ela consiste em dividir (1.5)–(1.6) por n e reconhecer estatísticas:

$$a \left[\frac{1}{n} \sum_{i=1}^n x_i^2 \right] + b \left[\frac{1}{n} \sum_{i=1}^n x_i \right] = \frac{1}{n} \sum_{i=1}^n x_i y_i,$$

$$a \underbrace{\left[\frac{1}{n} \sum_{i=1}^n x_i \right]}_{\bar{x}} + b = \underbrace{\left[\frac{1}{n} \sum_{i=1}^n y_i \right]}_{\bar{y}};$$

ou

$$a \left[\frac{1}{n} \sum_{i=1}^n x_i^2 \right] + b\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i y_i, \\ a\bar{x} + b = \bar{y}, \quad (1.10)$$

$$a \left[\frac{1}{n} \sum_{i=1}^n x_i^2 \right] + [\bar{y} - a\bar{x}] \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i y_i, \\ a \left[\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \right] = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}. \quad (1.11)$$

É possível reconhecer a variância de $\mathbf{x}$ e a covariância entre $\mathbf{x}$ e $\mathbf{y}$ nas expressões acima:

$$\text{Var}\{\mathbf{x}\} = c_{xx} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\ = \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\ = \frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{2\bar{x}}{n} \sum_{i=1}^n x_i + \bar{x}^2 \\ = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2; \quad (1.12)$$

$$\text{Cov}\{\mathbf{x}\} = c_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \\ = \frac{1}{n} \sum_{i=1}^n (x_i y_i - x_i \bar{y} - y_i \bar{x} + \bar{x} \bar{y}) \\ = \frac{1}{n} \sum_{i=1}^n x_i y_i - \frac{\bar{x}}{n} \sum_{i=1}^n y_i - \frac{\bar{y}}{n} \sum_{i=1}^n x_i + \bar{x} \bar{y} \\ = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}. \quad (1.13)$$

O desvio-padrão s_x é a raiz quadrada da variância:

$$s_x^2 \equiv c_{xx}. \quad (1.14)$$

Segue-se de (1.10)–(1.13) que

$$a = \frac{c_{xy}}{c_{xx}}, \quad (1.15)$$

$$b = \bar{y} - a\bar{x}. \quad (1.16)$$

Vale a pena incluir um descritor da *qualidade do ajuste da reta*, o coeficiente de correlação r_{xy} :

$$r_{xy} = \frac{c_{xy}}{s_x s_y}. \quad (1.17)$$

Isso nos leva a nosso primeiro problema:

1.1 Regressão linear por mínimos quadrados.

- Escreva uma rotina `stat2` para calcular a média e a variância de um array $\mathbf{x}$.
- Escreva uma rotina `covar` para calcular a covariância entre dois arrays $\mathbf{x}$ e $\mathbf{y}$.
- Escreva uma rotina `reglin` para obter a e b a partir de dois arrays $\mathbf{x}$ e $\mathbf{y}$.

1.2 Escreva um programa `reglinT0xy` para ler o arquivo `compareT0.tdat` e calcular a e b .

1.3 Plote a reta $y = ax + b$ obtida.

Capítulo 2

A regressão $y = ax$

Uma regressão mais simples, e muito comum, é:

$$y = ax. \quad (2.1)$$

Vamos precisar de um modelo estocástico para (2.1). Escolhemos

$$Y = ax + \mathcal{E} \quad (2.2)$$

com $E\{\mathcal{E}\} = 0$. O valor esperado de Y é

$$E\{Y\} = ax. \quad (2.3)$$

Neste modelo tanto a quando x são determinísticos. A principal consequência é que Y é *homocedástico* com

$$\text{Var}\{Y\} = \text{Var}\{\mathcal{E}\}. \quad (2.4)$$

Nossa função objetivo agora é

$$F(a; \mathbf{x}, \mathbf{y}) = \frac{1}{n} \sum_{i=1}^n [ax_i - y_i]^2. \quad (2.5)$$

Derivamos em relação a a , e igualamos a zero:

$$\begin{aligned} \frac{dF}{da} &= 0, \\ \frac{2}{n} \sum_{i=1}^n [ax_i - y_i] x_i &= 0, \\ a \left[\sum_{i=1}^n x_i^2 \right] &= \sum_{i=1}^n x_i y_i, \\ a &= \frac{\sum_{i=1}^n x_i y_i}{\sum_{i=1}^n x_i^2}. \end{aligned} \quad (2.6)$$

A regressão “pela origem” envolve momentos em relação à origem! É conveniente definir

$$m_{xx} \equiv \frac{1}{n} \sum_{i=1}^n x_i^2, \quad (2.7)$$

$$m_{yy} \equiv \frac{1}{n} \sum_{i=1}^n y_i^2, \quad (2.8)$$

$$m_{xy} \equiv \frac{1}{n} \sum_{i=1}^n x_i y_i. \quad (2.9)$$

Nessa notação,

$$a = \frac{m_{xy}}{m_{xx}}.$$

O “erro” envolvido na estimativa de a pode ser obtido se nós re-interpretarmos a (e y_i) como variáveis aleatórias, e se supusermos que os Y_i s são independentes:

$$A = \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}. \quad (2.10)$$

O valor esperado de A é

$$\begin{aligned} E\{A\} &= \frac{\sum_{i=1}^n x_i E\{Y_i\}}{\sum_{i=1}^n x_i^2}, \\ &= \frac{\sum_{i=1}^n x_i a x_i}{\sum_{i=1}^n x_i^2} = a. \end{aligned} \quad (2.11)$$

Portanto, A é um estimador não-enviesado de a . A variância de A é

$$\begin{aligned} \text{Var}\{A\} &= \frac{\sum_{i=1}^n x_i^2 \text{Var}\{Y\}}{\left[\sum_{i=1}^n x_i^2\right]^2} \\ &= \frac{\sum_{i=1}^n x_i^2}{\left[\sum_{i=1}^n x_i^2\right]^2} \text{Var}\{\mathcal{E}\} \\ &= \frac{\text{Var}\{\mathcal{E}\}}{\sum_{i=1}^n x_i^2}. \end{aligned} \quad (2.12)$$

O estimador para $\text{Var}\{\mathcal{E}\}$ é o quadrado do erro padrão de estimativa s_e^2 :

$$\begin{aligned} s_e^2 &= \frac{1}{n} \sum_{i=1}^n [y_i - ax_i]^2 \\ &= \frac{1}{n} \sum_{i=1}^n [y_i^2 - 2ax_i y_i + a^2 x_i^2] \\ &= \frac{1}{n} \left[\sum_{i=1}^n y_i^2 - 2a \sum_{i=1}^n x_i y_i + a^2 \sum_{i=1}^n x_i^2 \right] \\ &= m_{yy} - 2am_{xy} + a^2 m_{xx}; \\ a &= \frac{m_{xy}}{m_{xx}} \Rightarrow \\ s_e^2 &= m_{yy} - 2 \frac{m_{xy}}{m_{xx}} m_{xy} + \frac{m_{xy}^2}{m_{xx}^2} m_{xx} \\ &= m_{yy} - \frac{m_{xy}^2}{m_{xx}} m_{yy} \end{aligned}$$

$$= [1 - q_{xy}^2] m_{yy}. \quad (2.13)$$

A variável

$$q_{xy} \equiv \frac{m_{xy}}{\sqrt{m_{xx}m_{yy}}} \quad (2.14)$$

funciona como o “coeficiente de correlação” natural para a regressão pela origem. Vamos chamá-la de “coeficiente de quorrelação”. Assim como acontece com r_{xy} definido em (1.17), a desigualdade de Schwarz garante que

$$-1 \leq q_{xy} \leq 1. \quad (2.15)$$

Uma regressão perfeita pela origem possui $q_{xy}^2 = 1$:

$$y_i = ax_i, \quad (2.16)$$

$$\begin{aligned} q_{xy} &= \frac{\frac{1}{n} \sum_{i=1}^n x_i a x_i}{\sqrt{\left[\frac{1}{n} \sum_{i=1}^n x_i^2 \right] \left[\frac{1}{n} \sum_{i=1}^n a^2 x_i^2 \right]}} \\ &= \frac{a m_{xx}}{\sqrt{a^2 m_{xx}^2}} = \frac{a}{\sqrt{a^2}} = \frac{a}{|a|} = \pm 1. \end{aligned} \quad (2.17)$$

Voltando a (2.12), o estimador para o erro de a , s_a , é

$$s_a = \sqrt{\frac{s_e^2}{\sum_{i=1}^n x_i^2}}. \quad (2.18)$$

Finalmente, o coeficiente de determinação, por definição, é

$$c_d = 1 - \frac{s_e^2}{s_y^2}. \quad (2.19)$$

Ao contrário do que acontece com a regressão $y = ax + b$ (à qual retornaremos na próxima aula), é notável que na regressão pela origem é possível que $c_d < 0$. Em outras palavras, é possível que o modelo $y = ax$ produza um erro padrão de estimativa *maior* que o desvio-padrão dos dados observados y_i . À luz de (2.13), fica evidente que o “coeficiente de determinação” (que denominaremos “coeficiente de quodeterminação”) natural para a regressão pela origem é

$$c_q = q_{xy}^2 = 1 - \frac{s_e^2}{m_{yy}}. \quad (2.20)$$

Tarefas:

2.1 Regressão linear através da origem por mínimos quadrados.

- Escreva uma rotina `reglina` para obter a , q_{xy} , s_e e s_a a partir de dois arrays $\mathbf{x}$ e $\mathbf{y}$.

2.2 Escreva um programa `reglinaT0xy` para ler o arquivo `compareT0.tdat` e calcular a , c_d , s_e e s_a .

2.3 Plote a reta $y = ax \pm s_e$ obtida.

Capítulo 3

Erros dos parâmetros de $y = ax + b$

Voltemos ao problema de obter a reta $y = ax + b$, mas agora incluindo os erros envolvidos em a e b .

Vamos seguir [Benjamin e Cornell \(1970, Chapter 4\)](#)

O modelo probabilístico que vamos usar é

$$Y = ax + b + \mathcal{E}, \quad (3.1)$$

onde Y é uma variável aleatória, $\mathcal{E}$ é uma variável aleatória que não depende de x e com média zero, e x por sua vez não é aleatório. Para um valor específico x_i ,

$$Y_i = ax_i + b + \mathcal{E}_i, \quad (3.2)$$

$$E\{Y_i\} = ax_i + b, \quad (3.3)$$

$$\text{Var}\{Y_i\} = \text{Var}\{\mathcal{E}_i\} = \text{Var}\{\mathcal{E}\}. \quad (3.4)$$

Em particular, e muito importante, $\text{Var}\{Y_i\}$ é *diferente* da quantidade

$$s_Y^2 = E\{(Y_i - \bar{Y})^2\}! \quad (3.5)$$

Interessantemente, parece mais fácil calcular os “erros” de a e b a partir de (1.8)–(1.9). Começemos por

$$A = \frac{n \sum x_i Y_i - (\sum x_j)(\sum Y_i)}{d_n}; \quad (3.6)$$

$$d_n = n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2. \quad (3.7)$$

A boa notícia é que o denominador d_n *não* é uma variável aleatória. Isso facilita muito as coisas. Além disso,

$$\begin{aligned} d_n &= n^2 \times \frac{1}{n} \sum_{i=1}^n x_i^2 - n^2 \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2 \\ &= n^2 \left\{ \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \right\} \\ &= n^2 s_x^2. \end{aligned} \quad (3.8)$$

Prosseguimos:

$$\begin{aligned}
A &= \frac{1}{n^2 s_x^2} \left\{ n \sum_{i=1}^n x_i Y_i - \sum_{i=1}^n \left(\sum_{j=1}^n x_j \right) Y_i \right\} \\
&= \frac{1}{n^2 s_x^2} \left\{ \sum_{i=1}^n \left[n x_i - \left(\sum_{j=1}^n x_j \right) \right] Y_i \right\}, \\
&= \frac{1}{n^2 s_x^2} \left\{ \sum_{i=1}^n [n x_i - n \bar{x}] Y_i \right\} \\
&= \frac{1}{n s_x^2} \left\{ \sum_{i=1}^n (x_i - \bar{x}) Y_i \right\} \tag{3.9}
\end{aligned}$$

O valor esperado de A é

$$\begin{aligned}
E\{A\} &= \frac{1}{n s_x^2} \sum_{i=1}^n (x_i - \bar{x}) E\{Y_i\} \\
&= \frac{1}{n s_x^2} \sum_{i=1}^n (x_i - \bar{x}) (a x_i + b) \\
&= \frac{a}{n s_x^2} \sum_{i=1}^n (x_i - \bar{x}) x_i + \underbrace{\frac{b}{n s_x^2} \sum_{i=1}^n (x_i - \bar{x})}_{=0} \\
&= \frac{a}{n s_x^2} \left[\sum_{i=1}^n x_i^2 - n \bar{x}^2 \right] \\
&= a. \tag{3.10}
\end{aligned}$$

Portanto, A é um estimador não-enviesado de a . A variância de A é

$$\begin{aligned}
\text{Var}\{A\} &= \frac{1}{(n s_x^2)^2} \left\{ \sum_{i=1}^n (x_i - \bar{x})^2 \text{Var}\{Y_i\} \right\}, \\
&= \frac{n}{n^2 s_x^4} \left\{ \frac{1}{n} \sum_{i=1}^n (\bar{x} - x_i)^2 \text{Var}\{Y_i\} \right\}, \\
&= \frac{n}{n^2 s_x^4} \{s_x^2 \text{Var}\{Y_i\}\}, \\
&= \frac{1}{n s_x^2} \text{Var}\{Y_i\} \tag{3.11}
\end{aligned}$$

$$= \frac{1}{n s_x^2} \text{Var}\{\mathcal{E}_i\}, \tag{3.12}$$

devido a (3.4).

Uma estimativa para $\text{Var}\{\mathcal{E}_i\}$ simples de implementar computacionalmente (embora ineficiente) é o *erro padrão de estimativa de y* ,

$$s_e^2 = \frac{1}{n} \sum_{i=1}^n (y_i - (a x_i + b))^2 \tag{3.13}$$

É possível evitar o cálculo por extenso de (3.13) se já tivermos calculado outras estatísticas. Vejamos:

$$\begin{aligned}
s_e^2 &= \frac{1}{n} \sum_{i=1}^n (y_i - (ax_i + b))^2 \\
&= \frac{1}{n} \sum_{i=1}^n \left([y_i - \bar{y}] - a[x_i - \bar{x}] + \underbrace{\bar{y} - a\bar{x} - b}_{=0} \right)^2 \\
&= \frac{1}{n} \sum_{i=1}^n ([y_i - \bar{y}] - a[x_i - \bar{x}])^2 \\
&= \frac{1}{n} \sum_{i=1}^n ([y_i - \bar{y}]^2 - 2a[x_i - \bar{x}][y_i - \bar{y}] + a^2[x_i - \bar{x}]^2) \\
&= s_y^2 - 2ac_{xy} + a^2s_x^2;
\end{aligned}$$

usando (1.15),

$$\begin{aligned}
&= s_y^2 - 2 \frac{c_{xy}^2}{s_x^2} + \frac{c_{xy}^2}{s_x^4} s_x^2 \\
&= s_y^2 - \frac{c_{xy}^2}{s_x^2 s_y^2} s_y^2 \\
&= [1 - r_{xy}^2] s_y^2.
\end{aligned} \tag{3.14}$$

A estimativa de erro de a (3.12) fica, portanto,

$$\begin{aligned}
s_a^2 &= \frac{s_e^2}{ns_x^2}, \\
s_a &= \frac{s_e}{n^{1/2}s_x}.
\end{aligned} \tag{3.15}$$

Para estimar $\text{Var}\{B\}$, é preferível partir de 1.16; note que agora, entretanto, A e B são estimadores de a e b ; portanto, escrevemos

$$B = \bar{Y} - A\bar{x}. \tag{3.16}$$

O valor esperado de B é

$$\begin{aligned}
E\{B\} &= E\{\bar{Y}\} - E\{A\}\bar{x} \\
&= a\bar{x} + b - a\bar{x} = b.
\end{aligned} \tag{3.17}$$

Portanto, B é um estimador não-enviesado de b .

Observe que $\bar{Y}$ e A não são variáveis aleatórias independentes. Em princípio,

$$\text{Cov}\{A, \bar{Y}\} = E\{A\bar{Y}\} - E\{A\}E\{\bar{Y}\}, \tag{3.18}$$

$$\begin{aligned}
E\{\bar{Y}\} &= E\left\{\frac{1}{n} \sum_{i=1}^n Y_i\right\} \\
&= \frac{1}{n} \sum_{i=1}^n E\{Y_i\}
\end{aligned}$$

$$\begin{aligned}
&= \frac{1}{n} \sum_{i=1}^n ax_i + b \\
&= a\bar{x} + b,
\end{aligned} \tag{3.19}$$

$$\begin{aligned}
E\{A\bar{Y}\} &= E\left\{\left[\frac{1}{ns_x^2} \sum_{i=1}^n (x_i - \bar{x}) Y_i\right] \left[\frac{1}{n} \sum_{j=1}^n Y_j\right]\right\} \\
&= E\left\{\left[\frac{1}{n^2 s_x^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x}) Y_i Y_j\right]\right\} \\
&= \frac{1}{n^2 s_x^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x}) E\{Y_i Y_j\} \\
&= \frac{1}{n^2 s_x^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x}) E\{(ax_i + b + \mathcal{E}_i)(ax_j + b + \mathcal{E}_j)\} \\
&= \frac{1}{n^2 s_x^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x}) \left[(ax_i + b)(ax_j + b) \right. \\
&\quad \left. + (ax_i + b) E\{\mathcal{E}_j\} + (ax_j + b) E\{\mathcal{E}_i\} + E\{\mathcal{E}_i \mathcal{E}_j\} \right] \\
&= \frac{1}{n^2 s_x^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x}) \left[(ax_i + b)(ax_j + b) + E\{\mathcal{E}_i \mathcal{E}_j\} \right] \\
&= \frac{1}{n^2 s_x^2} \sum_{i=1}^n \sum_{j=1}^n (x_i - \bar{x}) \left[(ax_i + b)(ax_j + b) + \delta_{ij} \text{Var}\{\mathcal{E}\} \right] \\
&= \frac{1}{s_x^2} \left[\frac{1}{n} \sum_{j=1}^n (ax_j + b) \right] \left[\frac{1}{n} \sum_{i=1}^n (ax_i + b) (x_i - \bar{x}) \right] \\
&\quad + \frac{\text{Var}\{\mathcal{E}\}}{n^2 s_x^2} \sum_{i=1}^n (x_i - \bar{x}) \\
&= \frac{1}{s_x^2} [a\bar{x} + b] \left[\frac{1}{n} \sum_{i=1}^n (ax_i^2 - ax_i \bar{x} + b(x_i - \bar{x})) \right] \\
&= \frac{1}{s_x^2} [a\bar{x} + b] \left\{ a \left[\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x} \frac{1}{n} \sum_{i=1}^n x_i \right] \right\} \\
&= \frac{1}{s_x^2} [a\bar{x} + b] a \underbrace{\left[\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \right]}_{s_x^2} \\
&= (a\bar{x} + b) a.
\end{aligned} \tag{3.20}$$

Nós agora reunimos (3.10), (3.18), (3.19), e (3.20):

$$\begin{aligned}
\text{Cov}\{A, \bar{Y}\} &= E\{A\bar{Y}\} - E\{A\} E\{\bar{Y}\} \\
&= a(a\bar{x} + b) - a(a\bar{x} + b) = 0.
\end{aligned} \tag{3.21}$$

Portanto, apesar de não serem independentes, A e $\bar{Y}$ são não-correlacionadas.

Prosseguimos para a variância de B :

$$\begin{aligned}
 \text{Var}\{B\} &= \text{Var}\{\bar{Y}\} + \bar{x}^2 \text{Var}\{A\} + 2\bar{x} \text{Cov}\{A, \bar{Y}\} \\
 &= \text{Var}\{\bar{Y}\} + \bar{x}^2 \text{Var}\{A\} \\
 &= \frac{1}{n} \text{Var}\{Y_i\} + \bar{x}^2 \frac{1}{ns_x^2} \text{Var}\{\mathcal{E}\} \\
 &= \frac{1}{n} \text{Var}\{\mathcal{E}\} + \bar{x}^2 \frac{1}{ns_x^2} \text{Var}\{\mathcal{E}\} \\
 &= \left[s_x^2 + \bar{x}^2\right] \frac{\text{Var}\{\mathcal{E}\}}{ns_x^2} \\
 &= \left(\frac{1}{n} \sum_{i=1}^n x_i^2\right) \text{Var}\{A\}.
 \end{aligned} \tag{3.22}$$

Tarefas:

3.1 Regressão linear por mínimos quadrados com a estimativa dos erros dos parâmetros.

- Escreva uma rotina `reglinpar` para obter a, b, r, s_e, s_a e s_b a partir de dois arrays $\mathbf{x}$ e $\mathbf{y}$.

3.2 Escreva um programa `reglinparT0xy` para ler o arquivo `compareT0.tdat` e calcular a, b, r, s_e, s_a e s_b .

3.3 Plote a reta $y = ax + b \pm s_e$ obtida. Como podemos visualizar s_a e s_b ?

Capítulo 4

Matrizes e concavidade

4.1 Transformações definidas e indefinidas

Definição 4.1 Uma transformação A é *positiva definida* quando, para qualquer $x \neq 0$,

$$x^T \cdot A \cdot x > 0.$$

Definição 4.2 Uma transformação A é *positiva semidefinida* quando, para qualquer x ,

$$x^T \cdot A \cdot x \geq 0.$$

Definição 4.3 Uma transformação A é *negativa definida* quando, para qualquer $x \neq 0$,

$$x^T \cdot A \cdot x < 0.$$

Definição 4.4 Uma transformação A é *negativa semidefinida* quando, para qualquer x ,

$$x^T \cdot A \cdot x \leq 0.$$

Quando A não é nem positiva semidefinida nem negativa semidefinida, ela é denominada *indefinida*.

O caso de transformações simétricas é particularmente interessante, pois todos os autovalores correspondentes são reais. Então, nós afirmamos, sem prova, o

Teorema 4.1 Se a transformação A é simétrica:

- A é positiva definida se e somente se todos os seus autovalores são positivos.
- A é positiva semidefinida se e somente se todos os seus autovalores são não-negativos.
- A é negativa definida se e somente se todos os seus autovalores são negativos.
- A é negativa semidefinida se e somente se todos os seus autovalores são não-positivos
- A é indefinida se e somente se possui autovalores positivos e negativos.

A título apenas de ilustração, suponha que A é simétrica e que todos os seus n autovalores λ_i sejam positivos. Então, na base E dos autovetores, um vetor qualquer $\mathbf{x} \neq \mathbf{0}$ do $\mathbb{R}^n$ pode ser escrito

$$[\mathbf{x}]_E = [x_1 \ x_2 \ \dots \ x_n]^\top,$$

e

$$\mathbf{x}^\top \cdot A \cdot \mathbf{x} = \lambda_1 x_1^2 + \lambda_2 x_2^2 + \dots \lambda_n x_n^2 > 0,$$

e A é positiva definida.

4.2 Máximos e mínimos de funções de mais de uma variável

Seja f uma função de n variáveis do $\mathbb{R}^n$ em $\mathbb{R}$:

$$\begin{aligned} f : \mathbb{R}^n &\rightarrow \mathbb{R} \\ (x_1, \dots, x_n) &\mapsto y = f(x_1, \dots, x_n). \end{aligned}$$

Definição 4.5 $f(x_1, \dots, x_n)$ possui um máximo em $\mathbf{x}_0 = (x_{01}, \dots, x_{0n})$ se $f(\mathbf{x}_0) > f(\mathbf{x})$ para todo $\mathbf{x}$ em uma vizinhança de $\mathbf{x}_0$.

Definição 4.6 $f(x_1, \dots, x_n)$ possui um mínimo em $\mathbf{x}_0 = (x_{01}, \dots, x_{0n})$ se $f(\mathbf{x}_0) < f(\mathbf{x})$ para todo $\mathbf{x}$ em uma vizinhança de $\mathbf{x}_0$.

Máximos ou mínimos de uma função são chamados de *extremos*. Cada ponto $\mathbf{x}_0$ correspondente é um *ponto extremo*.


Exemplo 4.1 A função

$$f(x, y) = (200 - (x^2 + y^2))/100$$

possui um máximo em $(x_0, y_0) = (0, 0)$.

Exemplo 4.2 Considere o parabolóide hiperbólico

$$z = (100 + x^2 - y^2)/100,$$



O ponto $(0, 0)$ é um ponto crítico.

Teorema 4.2 (Piskounov, 1969, Cap. VIII, Seção 17, Teorema 1) Se $\mathbf{x}_0$ é um ponto extremo da função f , então ou $\nabla f(\mathbf{x}_0) = \mathbf{0}$, ou o $\nabla f(\mathbf{x}_0)$ não existe.

Definição 4.7 Dizemos que $\mathbf{x}_0$ é um ponto crítico de f se $\nabla f(\mathbf{x}_0) = \mathbf{0}$.

É relativamente fácil intuir “graficamente” o Teorema 4.2: na figura 4.1, note que se em um determinado ponto (x_0, y_0) ∇f existe e é $\neq \mathbf{0}$, então sempre podemos caminhar no sentido de ∇f para valores maiores de f , ou no sentido contrário para valores menores.

Note também que a nulidade ou não-existência do gradiente é uma condição necessária para a ocorrência de um extremo, porém não suficiente; e que portanto um ponto crítico pode não ser um ponto extremo. Por exemplo, a função do exemplo 4.2,

$$f(x, y) = (100 + x^2 - y^2)/100,$$

é tal que $\nabla f(0, 0) = \mathbf{0}$; porém, $(0, 0)$ não é nem um ponto de máximo nem de mínimo. Neste caso, dizemos que $(0, 0)$ é um *ponto de sela*.

Surge portanto a questão: se $\nabla f(\mathbf{x}_0) = \mathbf{0}$, e portanto $\mathbf{x}_0$ é um ponto crítico, como saber se $\mathbf{x}_0$ é um ponto de máximo, de mínimo, ou de sela?




Figura 4.1: (a) o vetor t é tangente à curva de nível Λ e a curva $\mathcal{L}$ é *localmente* paralela a Λ ; (b) o vetor t é perpendicular à curva de nível Λ e a curva $\mathcal{L}$ é *localmente* perpendicular a Λ .

Suponha que f possui derivadas pelo menos até ordem 2 e considere uma expansão em série de Taylor até ordem 2 em torno de x_0 :

$$\begin{aligned} f(x_k) &= f(x_{0k}) + \frac{\partial f(x_{0k})}{\partial x_i} (x_i - x_{0i}) + \frac{1}{2!} \frac{\partial^2 f(x_{0k})}{\partial x_i \partial x_j} (x_i - x_{0i})(x_j - x_{0j}) + \dots \\ &= f(x_{0k}) + \frac{1}{2!} \frac{\partial^2 f(x_{0k})}{\partial x_i \partial x_j} (x_i - x_{0i})(x_j - x_{0j}) + \dots \end{aligned} \quad (4.1)$$

pois $\nabla f(x_0) = \mathbf{0}$.

Note que estamos utilizando sistematicamente notação indicial em (4.1). Note também que a *matriz Hessiana*

$$H_{E,ij} = \frac{\partial^2 f(x_{0k})}{\partial x_i \partial x_j} \quad (4.2)$$

é simétrica: existem n autovetores mutuamente perpendiculares, e n autovalores reais. Inicialmente, nós associamos as coordenadas x_i com a base canônica E , e enfatizamos esse fato em (4.2). Mas é muito mais simples entender as coisas na base (que também é ortogonal) F dos autovetores! Sejam agora, portanto,

$$[x_0]_F = \begin{bmatrix} \xi_{01} \\ \xi_{02} \\ \vdots \\ \xi_{0n} \end{bmatrix} \quad \text{e} \quad [x]_F = \begin{bmatrix} \xi_1 \\ \xi_2 \\ \vdots \\ \xi_n \end{bmatrix}$$

as coordenadas de x_0 e x na base F ; nessa base, a matriz hessiana é diagonal:

$$H_{F,ij} = \frac{\partial^2 f(\xi_{0i})}{\partial \xi_i \partial \xi_j} = \lambda_{(i)} \delta_{ij}, \quad (4.3)$$

onde os λ_i s são os autovalores da transformação H . Abusando ligeiramente da notação, utilizemos $f(\xi_1, \dots, \xi_n)$ para indicar a *a mesma função* f porém nas coordenadas da base F . Expandido em série de Taylor temos agora,

$$f(\xi_k) = f(\xi_{0k}) + \frac{1}{2!} \frac{\partial^2 f(\xi_{0k})}{\partial \xi_i \partial \xi_j} (\xi_i - \xi_{0i})(\xi_j - \xi_{0j}) + \dots$$

$$\begin{aligned}
&= f(\xi_{0k}) + \frac{1}{2!} \lambda_{(i)} \delta_{ij} (\xi_i - \xi_{0i}) (\xi_j - \xi_{0j}) + \dots \\
&= f(\xi_{0k}) + \frac{1}{2!} \lambda_{(i)} (\xi_i - \xi_{0i}) (\xi_i - \xi_{0i}) + \dots
\end{aligned}$$

Fazendo $\Delta \xi_i = (\xi_i - \xi_{0i})$ e escrevendo por extenso, portanto,

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \frac{1}{2!} \sum_{i=1}^n \lambda_i \Delta \xi_i^2 + \dots \quad (4.4)$$

A situação agora é bastante clara. Em uma vizinhança de $\mathbf{x}_0$ em que (4.4) seja suficientemente acurada, se todos os λ_i s forem positivos, $f(\mathbf{x}) > f(\mathbf{x}_0)$, e portanto $\mathbf{x}_0$ é um ponto de mínimo. Analogamente, se todos os λ_i s forem negativos, $f(\mathbf{x}) < f(\mathbf{x}_0)$, e portanto ξ_0 é um ponto de mínimo. Caso contrário, $\mathbf{H}$ ou é semidefinida (positiva ou negativa) ou é indefinida. Nos dois primeiros casos, existem um ou mais autovalores nulos, e $\mathbf{H}$ é dita *singular*. No último caso, $\mathbf{H}$ é indefinida. Em resumo, nós agora temos o [Lambers \(2014\)](#):

Teorema 4.3

Se $\mathbf{H}$ é positiva definida em $\mathbf{x}_0$, $\mathbf{x}_0$ é um mínimo local.

Se $\mathbf{H}$ é negativa definida em $\mathbf{x}_0$, $\mathbf{x}_0$ é um máximo local.

Se $\mathbf{H}$ possui autovalores positivos e negativos, $\mathbf{x}_0$ é um ponto de sela.

Se $\mathbf{H}$ é *singular* (isto é, se existem autovalores nulos), nada se pode informar, e $\mathbf{x}_0$ pode ser um ponto de máximo, de mínimo ou de sela, mas isso precisa ser definido por outras informações sobre f .

4.3 Multiplicadores de Lagrange

Nesta seção vamos seguir de perto, inicialmente, [Piskounov \(1969, Cap VIII, seção 18\)](#). Considere o problema de obter o máximo ou mínimo de

$$u = f(x, y) \quad (4.5)$$

sujeito à *restrição*

$$g(x, y) = 0. \quad (4.6)$$

Um ataque direto envolve resolver a segunda equação, obter $y = y(x)$, e substituir na primeira:

$$u(x) = f(x, y(x)).$$

Note que estamos misturando liberalmente o nome de uma função ($u(x)$) com seu valor (u). A última equação acima leva à condição necessária para a existência de um máximo ou mínimo:

$$\frac{du}{dx} = \frac{\partial f}{\partial x} + \frac{\partial f}{\partial y} \frac{dy}{dx} = 0.$$

O problema pode ser resolvido, mas requer a obtenção da função (implícita) $y = y(x)$ a partir de $g(x, y) = 0$.

O ponto de extremo pode ser obtido sem se resolver explicitamente para $y(x)$, entretanto. Note que, de (4.6), $dg = 0$. Portanto, temos duas equações

$$\frac{\partial f}{\partial x} + \frac{\partial f}{\partial y} \frac{dy}{dx} = 0, \quad (4.7)$$

$$\frac{\partial g}{\partial x} + \frac{\partial g}{\partial y} \frac{dy}{dx} = 0. \quad (4.8)$$

Segue-se que para uma constante arbitrária λ

$$\left(\frac{\partial f}{\partial x} + \frac{\partial f}{\partial y} \frac{dy}{dx} \right) - \lambda \left(\frac{\partial g}{\partial x} + \frac{\partial g}{\partial y} \frac{dy}{dx} \right) = 0, \quad (4.9)$$

$$\left(\frac{\partial f}{\partial x} - \lambda \frac{\partial g}{\partial x} \right) + \left(\frac{\partial f}{\partial y} - \lambda \frac{\partial g}{\partial y} \right) \frac{dy}{dx} = 0 \quad (4.10)$$

A última equação acima pode ser satisfeita independentemente de dy/dx se ambos os parênteses forem nulos. Podemos agora resolver um sistema de 3 equações em 3 incógnitas:

$$\frac{\partial f}{\partial x} - \lambda \frac{\partial g}{\partial x} = 0, \quad (4.11)$$

$$\frac{\partial f}{\partial y} - \lambda \frac{\partial g}{\partial y} = 0, \quad (4.12)$$

$$g(x, y) = 0. \quad (4.13)$$

Isso é o mesmo que formar

$$F(x, y, \lambda) = f(x, y) - \lambda g(x, y)$$

e impor

$$\frac{\partial F}{\partial x} = 0, \quad (4.14)$$

$$\frac{\partial F}{\partial y} = 0, \quad (4.15)$$

$$\frac{\partial F}{\partial \lambda} = 0. \quad (4.16)$$

λ é denominado o *multiplicador de Lagrange*.

Uma generalização é: ache o máximo/mínimo de

$$u = f(x_1, x_2, \dots, x_n) = f(x_k)$$

sujeito a

$$g_1(x_1, x_2, \dots, x_n) = g_1(x_k) = 0,$$

$$g_2(x_1, x_2, \dots, x_n) = g_2(x_k) = 0,$$

$\vdots$

$$g_m(x_1, x_2, \dots, x_n) = g_m(x_k) = 0.$$

Formamos a função

$$F(x_1, x_2, \dots, x_n, \lambda_1, \lambda_2, \dots, \lambda_m) = f(x_k) - \lambda_l g_l(x_k),$$

e impomos

$$\frac{\partial F}{\partial x_k} = 0, \quad k = 1, 2, \dots, n, \quad (4.17)$$

$$\frac{\partial F}{\partial \lambda_l} = 0, \quad l = 1, 2, \dots, m. \quad (4.18)$$

Exemplo 4.3 Dados $x_1, x_2, \dots, x_n$ com $x_i > 0$, obtenha o máximo de

$$u = [x_1 \times x_2 \dots \times x_n]^{1/n}$$

sujeito a

$$x_1 + x_2 + \dots + x_n - a = 0.$$

SOLUÇÃO

Faça

$$F(x_k, \lambda) = [x_1 \times x_2 \dots \times x_n]^{1/n} - \lambda(x_1 + x_2 + \dots + x_n - a)$$

Agora

$$\begin{aligned} \frac{\partial F}{\partial x_k} &= \frac{1}{n} [x_1 \times x_2 \dots \times x_n]^{1/n-1} \prod_{x_l \neq x_k} x_l - \lambda \\ &= \frac{1}{n} [x_1 \times x_2 \dots \times x_n]^{1/n-1} \frac{[x_1 \times x_2 \dots \times x_n]}{x_k} - \lambda \\ &= \frac{1}{n} \frac{[x_1 \times x_2 \dots \times x_n]^{1/n}}{x_k} - \lambda = \frac{1}{n} \frac{u}{x_k} - \lambda \end{aligned}$$

e

$$\frac{\partial F}{\partial x_k} = 0 \Rightarrow \frac{1}{n} \frac{u}{x_k} = \lambda \Rightarrow x_k = \frac{u}{n\lambda}.$$

Portanto, $x_1 = \dots = x_n$; mas

$$\begin{aligned} x_1 + x_2 + \dots + x_n &= a, \\ nx_k &= a, \\ x_k &= \frac{a}{n}; \\ u &= \left[\left(\frac{a}{n} \right)^n \right]^{1/n} = \frac{a}{n} \end{aligned}$$

O máximo portanto é a/n , donde se segue a desigualdade da média aritmética-geométrica:

$$[x_1 \times x_2 \dots \times x_n]^{1/n} \leq \frac{a}{n} = \frac{x_1 + x_2 + \dots + x_n}{n} \quad \blacksquare$$

Capítulo 5

steep: Steepest descent method for non-linear least squares

5.1 Before Gavin

Let us follow [Strikwerda \(2004\)](#), Chapter 14. We want to solve

$$[A]_{N \times N} [x]_{N \times 1} = [b]_{N \times 1}, \quad (5.1)$$

where $[A]$ is symmetric and positive definite, for x . Indicial notation is usually much simpler to use, so let us write instead

$$A_{ij}x_j = b_i. \quad (5.2)$$

Put

$$F(\xi_k) = \frac{1}{2} [\xi_i - x_i] A_{ij} [\xi_j - x_j]. \quad (5.3)$$

Then, clearly F has a minimum at $\xi_k = x_k$.

Now write something more complicated (how do people come up with these ideas?). The function

$$\begin{aligned} E(\xi_k) &\equiv F(\xi_k) - F(0_k) \\ &= \frac{1}{2} [\xi_i - x_i] A_{ij} [\xi_j - x_j] - \frac{1}{2} x_i A_{ij} x_j \\ &= \frac{1}{2} \xi_i A_{ij} \xi_j - \frac{1}{2} x_i A_{ij} \xi_j - \frac{1}{2} \xi_i A_{ij} x_j + \frac{1}{2} x_i A_{ij} x_j - \frac{1}{2} x_i A_{ij} x_j \\ &= \frac{1}{2} \xi_i A_{ij} \xi_j - \frac{1}{2} x_j A_{ji} \xi_i - \frac{1}{2} \xi_i A_{ij} x_j \\ &= \frac{1}{2} \xi_i A_{ij} \xi_j - \frac{1}{2} \xi_i A_{ij} x_j - \frac{1}{2} \xi_i A_{ij} x_j \\ &= \frac{1}{2} \xi_i A_{ij} \xi_j - \xi_i b_i \end{aligned} \quad (5.4)$$

also has a minimum at $\xi_k = x_k$. The gradient of $E(\xi_k)$ is the function

$$G(\xi_k) = \nabla E = \frac{\partial E}{\partial \xi_k} \mathbf{e}_k.$$

Now

$$\frac{\partial E}{\partial \xi_k} = \frac{1}{2} \xi_i A_{ij} \frac{\partial \xi_j}{\partial \xi_k} + \frac{1}{2} \frac{\partial \xi_i}{\partial \xi_k} A_{ij} \xi_j - \frac{\partial \xi_i}{\partial \xi_k} b_i$$

$$\begin{aligned}
&= \frac{1}{2} \xi_i A_{ij} \delta_{jk} + \frac{1}{2} \delta_{ik} A_{ij} \xi_j - \delta_{ik} b_i \\
&= \frac{1}{2} \xi_i A_{ik} + \frac{1}{2} A_{kj} \xi_j - b_k \\
&= \frac{1}{2} A_{ki} \xi_i + \frac{1}{2} A_{kj} \xi_j - b_k \\
&= A_{kj} \xi_j - b_k,
\end{aligned} \tag{5.5}$$

or

$$\nabla E = \mathbf{A} \cdot \boldsymbol{\xi} - \mathbf{b}.$$

The gradient points to the direction of steepest *ascent*. Therefore, we search in the *opposite* direction, that of steepest *descent*. Start from an initial guess $\boldsymbol{\xi} = \mathbf{x}^0$; set

$$\begin{aligned}
\mathbf{r}^p &= -\nabla E = \mathbf{b} - \mathbf{A} \cdot \mathbf{x}^p, \\
r_i^p &= b_i - A_{ij} x_j^p.
\end{aligned}$$

and now move to

$$\mathbf{x}^{p+1} = \mathbf{x}^p + \alpha^p \mathbf{r}^p. \tag{5.6}$$

We adopt the convention that repeated *superscripts* (p in this case) *do not* imply summation. The function E at the new estimate is

$$\begin{aligned}
E(\mathbf{x}_k^{p+1}) &= E(\mathbf{x}^p + \alpha^p \mathbf{r}^p) \\
&= \frac{1}{2} [x_i^p + \alpha^p r_i^p] A_{ij} [x_j^p + \alpha^p r_j^p] - [x_i^p + \alpha^p r_i^p] b_i \\
&= \frac{1}{2} x_i^p A_{ij} x_j^p + \frac{1}{2} \alpha^p r_i^p A_{ij} x_j^p + \frac{1}{2} x_i^p A_{ij} \alpha^p r_j^p + \frac{1}{2} (\alpha^p)^2 r_i^p A_{ij} r_j^p \\
&\quad - [x_i^p + \alpha^p r_i^p] b_i \\
&= \underbrace{\frac{1}{2} x_i^p A_{ij} x_j^p - x_i^p b_i + \frac{1}{2} \alpha^p r_i^p A_{ij} x_j^p + \frac{1}{2} x_i^p A_{ij} \alpha^p r_j^p}_{E(\mathbf{x}_k^p)} + \\
&\quad \frac{1}{2} (\alpha^p)^2 r_i^p A_{ij} r_j^p - \alpha^p r_i^p b_i \\
&= E(\mathbf{x}_k^p) + \underbrace{\frac{1}{2} \alpha^p r_i^p A_{ij} x_j^p + \frac{1}{2} x_j^p A_{ji} \alpha^p r_i^p}_{A_{ij}=A_{ji}} + \frac{1}{2} (\alpha^p)^2 r_i^p A_{ij} r_j^p - \alpha^p r_i^p b_i \\
&= E(\mathbf{x}_k^p) + \alpha^p r_i^p A_{ij} x_j^p - \alpha^p r_i^p b_i + \frac{1}{2} (\alpha^p)^2 r_i^p A_{ij} r_j^p \\
&= E(\mathbf{x}_k^p) + \alpha^p r_i^p \underbrace{\left[A_{ij} x_j^p - b_i \right]}_{-r_i^p} + \frac{1}{2} (\alpha^p)^2 r_i^p A_{ij} r_j^p \\
&= E(\mathbf{x}_k^p) - \alpha^p r_i^p r_i^p + \frac{1}{2} (\alpha^p)^2 r_i^p A_{ij} r_j^p.
\end{aligned} \tag{5.7}$$

The trick now is to choose α^p to minimize (5.7) above:

$$-r_i^p r_i^p + \alpha^p r_i^p A_{ij} r_j^p = 0,$$

$$\alpha^p = \frac{r_i^p r_i^p}{r_i^p A_{ij} r_j^p} \quad (5.8)$$

The successor r_i^{p+1} can be calculated directly,

$$\begin{aligned} r_i^{p+1} &= b_i - A_{ij} x_j^{p+1} \\ &= b_i - A_{ij} \left[x_j^p + \alpha^p r_j^p \right] \\ &= b_i - A_{ij} x_j^p - \alpha^p A_{ij} r_j^p \\ &= r_i^p - \alpha^p A_{ij} r_j^p \end{aligned} \quad (5.9)$$

As (Strikwerda, 2004, p. 374) points out, there are some interesting consequences of (5.8). First,

$$\begin{aligned} \mathbf{r}^{p+1} \cdot \mathbf{r}^p &= r_i^{p+1} r_i^p \\ &= \left[b_i - A_{ij} x_j^{p+1} \right] r_i^p \\ &= \left[b_i - A_{ij} (x_j^p + \alpha^p r_j^p) \right] r_i^p \\ &= \left[r_i^p - \alpha^p A_{ij} r_j^p \right] r_i^p \\ &= r_i^p r_i^p - \frac{r_i^p r_i^p}{r_i^p A_{ij} r_j^p} r_i^p A_{ij} r_j^p \\ &= 0. \end{aligned}$$

This means that successive increments are orthogonal. Neat. Moreover, for the optimal α^p in (5.8) $E(x_k^{p+1})$ decreases continually:

$$\begin{aligned} E(x_k^{p+1}) &= E(x_k^p) - \frac{r_i^p r_i^p}{r_i^p A_{ij} r_j^p} r_i^p r_i^p + \frac{1}{2} \left(\frac{r_i^p r_i^p}{r_i^p A_{ij} r_j^p} \right)^2 r_i^p A_{ij} r_j^p \\ &= E(x_k^p) - \frac{1}{2} \frac{(r_i^p r_i^p)^2}{r_i^p A_{ij} r_j^p} < E(x_k^p) \end{aligned}$$

(because A_{ij} is positive definite). It appears that the steepest descent method has the guarantee that it will converge to the solution; see Strikwerda (2004) for more.

We now try our first algorithmcx thing.

Algorithm 1 Steepest descent: Solve $\mathbf{A} \cdot \mathbf{x} = \mathbf{b}$

Require: A_{ij} is symmetric positive-definite

Specify a convergence criterion $\epsilon > 0$

$p \leftarrow 0$

Choose $\mathbf{x}^0$

$\mathbf{r}^0 \leftarrow \mathbf{b} - \mathbf{A} \cdot \mathbf{x}^0$

while $|\mathbf{r}^p| > \epsilon$ **do**

$\alpha^p \leftarrow \mathbf{r}^p \cdot \mathbf{r}^p / \mathbf{r}^p \cdot \mathbf{A} \cdot \mathbf{r}^p$

$\mathbf{x}^{p+1} \leftarrow \mathbf{x}^p + \alpha^p \mathbf{r}^p$

$\mathbf{r}^{p+1} \leftarrow \mathbf{r}^p - \alpha^p \mathbf{A} \cdot \mathbf{r}^p$

$p \leftarrow p + 1$

end while

5.2 Adapting to find the best parameter set θ

Let

$$\hat{\mathbf{y}} = \hat{\mathbf{y}}(\mathbf{x}, \theta), \quad (5.10)$$

be an approximation

$$\hat{\mathbf{y}} \approx \mathbf{y} \quad (5.11)$$

with $\mathbf{y} \in \mathbb{R}^M$, $\mathbf{x} \in \mathbb{R}^M \times \mathbb{R}^L$ ($\mathbf{x}$ is an $M \times L$ “matrix”) and $\theta \in \mathbb{R}^N$. Here, the function $\hat{\mathbf{y}}(\mathbf{x}, \theta)$ has an assumed deterministic relation between the independent data $\mathbf{x}$ and the dependent data $\mathbf{y}$ and a vector θ of *parameters*; our objective is to find θ such that the difference between $\hat{\mathbf{y}}$ and $\mathbf{y}$ is minimal in some sense.

We want to find the minimum of

$$F(\theta) \equiv \frac{1}{2} [\hat{\mathbf{y}} - \mathbf{y}] \cdot \mathbf{W} \cdot [\hat{\mathbf{y}} - \mathbf{y}] \quad (5.12)$$

where W_{ij} is symmetric positive-definite. Can we use steepest descent in this case? Is the adaptation easy? Let us try:

$$F(\theta_k) = \frac{1}{2} \hat{y}_i W_{ij} \hat{y}_j - \frac{1}{2} \hat{y}_i W_{ij} y_j - \frac{1}{2} y_i W_{ij} \hat{y}_j + \frac{1}{2} y_i W_{ij} y_j. \quad (5.13)$$

Clearly there is another layer now, because $\hat{\mathbf{y}} = \hat{\mathbf{y}}(\mathbf{x}, \theta)$. So we are not aiming directly for a solution in $\hat{\mathbf{y}}$, but rather in θ . Let us try to adapt! Put

$$\begin{aligned} E(\theta_k) &= \frac{1}{2} \hat{y}_i W_{ij} \hat{y}_j - \frac{1}{2} \hat{y}_i W_{ij} y_j - \frac{1}{2} y_i W_{ij} \hat{y}_j \\ &= \frac{1}{2} \hat{y}_i W_{ij} \hat{y}_j - \frac{1}{2} \hat{y}_i W_{ij} y_j - \frac{1}{2} y_j W_{ji} \hat{y}_i \\ &= \frac{1}{2} \hat{y}_i W_{ij} \hat{y}_j - \frac{1}{2} \hat{y}_i W_{ij} y_j - \frac{1}{2} y_j W_{ij} \hat{y}_i \\ &= \frac{1}{2} \hat{y}_i W_{ij} \hat{y}_j - \underbrace{\hat{y}_i W_{ij} y_j}_{b_i} \\ &= \frac{1}{2} \hat{y}_i W_{ij} \hat{y}_j - \hat{y}_i b_i. \end{aligned} \quad (5.14)$$

Here we have subtracted the constant term $y_i W_{ij} y_j / 2$ in $F(\theta_k)$; the remaining terms produce $E(\theta_k) = 0$ when $\hat{y}_k = 0$. (5.14) is the counterpart of (5.4). Let us now calculate the gradient of this new $E(\theta_k)$:

$$\begin{aligned} \nabla E &= \frac{\partial E}{\partial \theta_k} \mathbf{e}_k; \\ \frac{\partial E}{\partial \theta_k} &= \frac{1}{2} \frac{\partial \hat{y}_i}{\partial \hat{y}_l} \frac{\partial \hat{y}_l}{\partial \theta_k} W_{ij} \hat{y}_j + \frac{1}{2} \hat{y}_i W_{ij} \frac{\partial \hat{y}_j}{\partial \hat{y}_l} \frac{\partial \hat{y}_l}{\partial \theta_k} - \frac{\partial \hat{y}_i}{\partial \hat{y}_l} \frac{\partial \hat{y}_l}{\partial \theta_k} b_i \\ &= \frac{1}{2} \delta_{il} \frac{\partial \hat{y}_l}{\partial \theta_k} W_{ij} \hat{y}_j + \frac{1}{2} \hat{y}_i W_{ij} \delta_{jl} \frac{\partial \hat{y}_l}{\partial \theta_k} - \delta_{il} \frac{\partial \hat{y}_l}{\partial \theta_k} b_i \\ &= \frac{1}{2} \frac{\partial \hat{y}_i}{\partial \theta_k} W_{ij} \hat{y}_j + \frac{1}{2} \hat{y}_i W_{ij} \frac{\partial \hat{y}_j}{\partial \theta_k} - \frac{\partial \hat{y}_i}{\partial \theta_k} b_i \\ &= \frac{1}{2} \frac{\partial \hat{y}_i}{\partial \theta_k} W_{ij} \hat{y}_j + \frac{1}{2} \hat{y}_j W_{ji} \frac{\partial \hat{y}_i}{\partial \theta_k} - \frac{\partial \hat{y}_i}{\partial \theta_k} b_i \end{aligned}$$

$$\begin{aligned}
&= \frac{\partial \hat{y}_i}{\partial \theta_k} W_{ij} \hat{y}_j - \frac{\partial \hat{y}_i}{\partial \theta_k} b_i \\
&= \frac{\partial \hat{y}_i}{\partial \theta_k} [W_{ij} \hat{y}_j - b_i] \\
&= J_{ki}^\top [W_{ij} \hat{y}_j - b_i]
\end{aligned} \tag{5.15}$$

where

$$J_{ik} \equiv \frac{\partial \hat{y}_i}{\partial \theta_k} \tag{5.16}$$

is the Jacobian matrix.

We need to be a little careful with the notation. In this part of the derivations, we will omit the $\mathbf{x}$ -dependence of $\hat{\mathbf{y}}$; since

$$\hat{y}_k = \hat{y}_k(\theta_l),$$

successive estimates should be superscripted:

$$\hat{y}_k^p = \hat{y}_k(\theta_l^p).$$

By the same token,

$$\begin{aligned}
J_{kl}(\theta_m^p) &= \frac{\partial \hat{y}_k(\theta_m^p)}{\partial \theta_l}, \\
J_{kl}^p &= \frac{\partial \hat{y}_k^p}{\partial \theta_l}.
\end{aligned}$$

Now, (5.15) is the counterpart of (5.5). In vector notation,

$$\nabla E = \mathbf{J}^\top \cdot [\mathbf{W} \cdot \hat{\mathbf{y}} - \mathbf{b}]. \tag{5.17}$$

We now set

$$\begin{aligned}
\mathbf{r}^p &= -\nabla E^p = -\mathbf{J}^{\top p} \cdot [\mathbf{W} \cdot \hat{\mathbf{y}}^p - \mathbf{b}], \\
r_k^p &= -J_{ki}^{\top p} [W_{ij} \hat{y}_j^p - b_i].
\end{aligned} \tag{5.18}$$

and move to

$$\boldsymbol{\theta}^{p+1} = \boldsymbol{\theta}^p + \alpha^p \mathbf{r}^p. \tag{5.19}$$

But now

$$\begin{aligned}
\hat{y}_k^{p+1} &= \hat{y}_k(\theta_l^{p+1}) \\
&= \hat{y}_k(\theta_l^p + \alpha^p r_l^p) \\
&\approx \hat{y}_k(\theta_l^p) + \frac{\partial \hat{y}_k^p}{\partial \theta_l} \alpha^p r_l^p \\
&= \hat{y}_k^p + \alpha^p J_{kl}^p r_l^p.
\end{aligned} \tag{5.20}$$

Admittedly, the profusion of superscripts in (5.20) above is heavy notation. On the other hand, it clearly marks at which step in the method

each quantity is being evaluated, and we deem it worth the extra amount of typing required. Proceeding with the help of (5.20),

$$\begin{aligned}
E\left(\theta_k^{p+1}\right) &= E\left(\theta_k^p + \alpha^p r_k^p\right) \\
&= \frac{1}{2} \widehat{y}_i^{p+1} W_{ij} \widehat{y}_j^{p+1} - \widehat{y}_i^{p+1} b_i \\
&\approx \frac{1}{2} [\widehat{y}_i^p + \alpha^p J_{il}^p r_l^p] W_{ij} [\widehat{y}_j^p + \alpha^p J_{jl}^p r_l^p] - [\widehat{y}_i^p + J_{il}^p \alpha^p r_l^p] b_i \\
&= \frac{1}{2} \widehat{y}_i^p A_{ij} \widehat{y}_j^p + \frac{1}{2} \alpha^p J_{il}^p r_l^p W_{ij} \widehat{y}_j^p + \frac{1}{2} \widehat{y}_i^p W_{ij} \alpha^p J_{jl}^p r_l^p \\
&\quad + \frac{1}{2} (\alpha^p)^2 J_{il}^p r_l^p W_{ij} J_{jm}^p r_m^p - [\widehat{y}_i^p + \alpha^p J_{il}^p r_l^p] b_i \\
&= \underbrace{\frac{1}{2} \widehat{y}_i^p W_{ij} \widehat{y}_j^p - \widehat{y}_i^p b_i}_{E(\theta_k^p)} + \frac{1}{2} \alpha^p J_{il}^p r_l^p W_{ij} \widehat{y}_j^p + \frac{1}{2} \widehat{y}_j^p W_{ji} \alpha^p J_{il}^p r_l^p \\
&\quad + \frac{1}{2} (\alpha^p)^2 J_{il}^p r_l^p W_{ij} J_{jm}^p r_m^p - \alpha^p J_{il}^p r_l^p b_i \\
&= E(\theta_k^p) + \alpha^p J_{il}^p r_l^p [W_{ij} \widehat{y}_j^p - b_i] + \frac{1}{2} (\alpha^p)^2 J_{il}^p r_l^p W_{ij} J_{jm}^p r_m^p \\
&= E(\theta_k^p) + \alpha^p r_l^p \underbrace{J_{li}^{\top p} [W_{ij} \widehat{y}_j^p - b_i]}_{-r_l^p} + \frac{1}{2} (\alpha^p)^2 J_{il}^p r_l^p W_{ij} J_{jm}^p r_m^p \\
&= E(\theta_k^p) - \alpha^p r_l^p r_l^p + \frac{1}{2} (\alpha^p)^2 J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p \tag{5.21}
\end{aligned}$$

Again, we choose α^p to minimize (5.21) above:

$$\begin{aligned}
0 &= -r_l^p r_l^p + \alpha^p r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p, \\
\alpha^p &= \frac{r_l^p r_l^p}{r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p}. \tag{5.22}
\end{aligned}$$

The successor r_k^{p+1} can only be calculated directly from r_k^p with a kludge. First, we need to truncate the Jacobian “at the previous time step”:

$$J_{ki}^{\top p+1} \approx J_{ki}^{\top p}, \tag{5.23}$$

Only then

$$\begin{aligned}
r_k^{p+1} &= J_{ki}^{\top p+1} [b_i - W_{ij} \widehat{y}_j^{p+1}] \approx J_{ki}^{\top p} [b_i - W_{ij} \widehat{y}_j^{p+1}] \\
&\approx J_{ki}^{\top p} [b_i - W_{ij} (\widehat{y}_j^p + \alpha^p J_{jl}^p r_l^p)] \\
&= J_{ki}^{\top p} [b_i - W_{ij} \widehat{y}_j^p - W_{ij} \alpha^p J_{jl}^p r_l^p] \\
&= r_k^p - \alpha^p J_{ki}^{\top p} W_{ij} J_{jl}^p r_l^p. \tag{5.24}
\end{aligned}$$

There are two truncated Taylor series expansions above, (5.20) and (5.23). It is not clear how they may affect rate of convergence or even convergence itself.

With this provision, as before we check for the orthogonality of successive $\mathbf{r}$ s:

$$\begin{aligned}
\mathbf{r}^{p+1} \cdot \mathbf{r} &= \left[r_k^p - \alpha^p J_{ki}^{\top p} W_{ij} J_{jl}^p r_l^p \right] r_k^p \\
&= r_k^p r_k^p - \frac{r_n^p r_n^p}{r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p} J_{ki}^{\top p} W_{ij} J_{jl}^p r_l^p r_k^p \\
&= r_k^p r_k^p - \frac{r_k^p J_{ki}^{\top p} W_{ij} J_{jl}^p r_l^p}{r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p} r_n^p r_n^p \\
&= r_k^p r_k^p - r_n^p r_n^p = 0.
\end{aligned} \tag{5.25}$$

Finally, put (5.22) in (5.21); this gives

$$\begin{aligned}
E(\theta_k^{p+1}) &= E(\theta_k^p) - \frac{r_n^p r_n^p}{r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p} r_l^p r_l^p \\
&\quad + \frac{1}{2} \left(\frac{r_n^p r_n^p}{r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p} \right)^2 r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p \\
&= E(\theta_k^p) - \frac{1}{2} \frac{(r_n^p r_n^p)^2}{r_l^p J_{li}^{\top p} W_{ij} J_{jm}^p r_m^p} < E(\theta_k^p)
\end{aligned} \tag{5.26}$$

because $J_{li}^{\top p} W_{ij} J_{jm}^p$ is symmetric positive definite.

We now need to change Algorithm 1 to find θ .

Algorithm 2 Steepest descent: Find θ that minimizes

$$F(\theta) = \frac{1}{2} [\hat{\mathbf{y}} - \mathbf{y}] \cdot \mathbf{W} \cdot [\hat{\mathbf{y}} - \mathbf{y}]$$

Require: A_{ij} is symmetric positive-definite

Specify a convergence criterion $\epsilon > 0$

$\mathbf{b} \leftarrow \mathbf{W} \cdot \mathbf{y}$

▷ “ $\leftarrow$ ” indicates a constant

$p \leftarrow 0$

Choose θ^0

Calculate $\hat{\mathbf{y}}^0 = \hat{\mathbf{y}}(\theta^0)$

Calculate $\mathbf{J}^0$

$\mathbf{r}^0 \leftarrow \mathbf{J}^{\top 0} [\mathbf{b} - \mathbf{W} \cdot \hat{\mathbf{y}}^0]$

while $|\mathbf{r}^p| > \epsilon$ **do**

$\alpha^p \leftarrow \mathbf{r}^p \cdot \mathbf{r}^p / (\mathbf{r}^p \cdot [\mathbf{J}^{\top p} \cdot \mathbf{W} \cdot \mathbf{J}^p] \cdot \mathbf{r}^p)$ ▷ Uses approx (5.20)

$\theta^{p+1} \leftarrow \theta^p + \alpha^p \mathbf{r}^p$ ▷ Uses approx (5.20)

$\mathbf{r}^{p+1} \leftarrow \mathbf{r}^p - \alpha^p [\mathbf{J}^{\top p} \cdot \mathbf{W} \cdot \mathbf{J}^p] \cdot \mathbf{r}^p$ ▷ Uses (5.20) and (5.23)

$p \leftarrow p + 1$

Calculate $\hat{\mathbf{y}}^p = \hat{\mathbf{y}}(\theta^p)$

Calculate $\mathbf{J}^p = \mathbf{J}(\theta^p)$

end while

But as we know this involves two truncated Taylor series. There is an alternative:

Algorithm 3 2nd version of Steepest descent: Find θ that minimizes

$$F(\theta) = \frac{1}{2} [\hat{\mathbf{y}} - \mathbf{y}]_{1 \times M}^T [\mathbf{W}]_{M \times M} [\hat{\mathbf{y}} - \mathbf{y}]_{M \times 1}$$

Require: A_{ij} is symmetric positive-definite

Specify a convergence criterion $\epsilon > 0$

$\mathbf{b} \leftarrow \mathbf{W} \cdot \mathbf{y}$

▷ “ $\leftarrow$ ” indicates a constant

$p \leftarrow 0$

Choose θ^0

$|\mathbf{r}^0| \leftarrow 2\epsilon$

Calculate $\hat{\mathbf{y}}^0 = \hat{\mathbf{y}}(\theta^0)$

Calculate $\mathbf{J}^0$

$\mathbf{r}^0 \leftarrow \mathbf{J}^{\top 0} [\mathbf{b} - \mathbf{W} \cdot \hat{\mathbf{y}}^0]$

while $|\mathbf{r}^p| > \epsilon$ **do**

 Calculate $\hat{\mathbf{y}}^p = \hat{\mathbf{y}}(\theta^p)$

 Calculate $\mathbf{J}^p = \mathbf{J}(\theta^p)$

$\mathbf{r}^p \leftarrow \mathbf{J}^{\top p} \cdot [\mathbf{b} - \mathbf{W} \cdot \hat{\mathbf{y}}^p]$

$\alpha^p \leftarrow \mathbf{r}^p \cdot \mathbf{r}^p / (\mathbf{r}^p \cdot [\mathbf{J}^{\top p} \cdot \mathbf{W} \cdot \mathbf{J}^p] \cdot \mathbf{r}^p)$

▷ Uses approx (5.20)

$\theta^{p+1} \leftarrow \theta^p + \alpha^p \mathbf{r}^p$

$p \leftarrow p + 1$

end while

5.3 After Gavin

The description here is quite detailed and long, and may in the future be moved to a proper place. It is heavily based on [Gavin \(2022\)](#) and code listings in Matlab cited therein.

Consider then a set of m “observed” data points $\mathbf{y} = (y_1, \dots, y_m)$ at the independent variable values $\mathbf{x} = ((x_{11}, \dots, x_{1l}), \dots, (x_{m1}, \dots, x_{ml}))$. A model may be proposed to approximate or estimate these points, of the type

$$\hat{\mathbf{y}} = f(\mathbf{x}, \mathbf{p}) \quad (5.27)$$

where $\mathbf{p} = (p_1, \dots, p_n)$ are n parameters that we want to find to get $\hat{\mathbf{y}}$ as “close” as possible to $\mathbf{y}$.

The next element is the objective function that we wish to minimize, namely

$$\chi^2(\mathbf{p}) \equiv [\hat{\mathbf{y}} - \mathbf{y}]_{1 \times m}^T [\mathbf{W}]_{m \times m} [\hat{\mathbf{y}} - \mathbf{y}]_{m \times 1} \quad (5.28)$$

[Gavin \(2022\)](#) mentions that $[\mathbf{W}]$ is often a diagonal matrix (which makes a lot of sense, and is the only case implemented in the routine):

$$W_{ij} = \frac{\delta_{ij}}{\sigma_{y(i)}^2}. \quad (5.29)$$

We translate (5.28) to indicial notation:

$$\chi^2(p_k) = [\hat{y}_i(p_k) - y_i] W_{ij} [\hat{y}_j(p_k) - y_j]; \quad (5.30)$$

then,

$$\frac{\partial \chi^2}{\partial p_k} = [\hat{y}_i(p_k) - y_i] W_{ij} \left[\frac{\partial \hat{y}_j}{\partial p_k} \right] + \left[\frac{\partial \hat{y}_i}{\partial p_k} \right] W_{ij} [\hat{y}_j(p_k) - y_j] \quad (5.31)$$

$$= [\hat{y}_i(p_k) - y_i] W_{ij} \left[\frac{\partial \hat{y}_j}{\partial p_k} \right] + [\hat{y}_i(p_k) - y_i] W_{ji} \left[\frac{\partial \hat{y}_j}{\partial p_k} \right] \quad (5.32)$$

which, since $[W]$ is symmetric, yields

$$= 2[\hat{y}_i(p_k) - y_i] W_{ij} \left[\frac{\partial \hat{y}_j}{\partial p_k} \right] \quad (5.33)$$

or

$$[\nabla \chi^2]_{1 \times n}^T = 2[[\hat{\mathbf{y}}] - \mathbf{y}]_{1 \times m}^T [W]_{m \times m} [J]_{m \times n} \quad (5.34)$$

where

$$J_{jk} = \frac{\partial \hat{y}_j}{\partial p_k} \quad (5.35)$$

are the elements of the jacobian matrix

$$[J]_{m \times n} = \begin{bmatrix} \frac{\partial y_1}{\partial p_1} & \frac{\partial y_1}{\partial p_2} & \dots & \frac{\partial y_1}{\partial p_n} \\ \frac{\partial y_2}{\partial p_1} & \frac{\partial y_2}{\partial p_2} & \dots & \frac{\partial y_2}{\partial p_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial p_1} & \frac{\partial y_m}{\partial p_2} & \dots & \frac{\partial y_m}{\partial p_n} \end{bmatrix}. \quad (5.36)$$

The gradient of χ^2 is

$$\begin{aligned} [\nabla \chi^2]_{n \times 1} &= [2[[\hat{\mathbf{y}}] - \mathbf{y}]_{1 \times m}^T [W]_{m \times m} [J]_{m \times n}]^T \\ &= 2[J]_{n \times m}^T [[\hat{\mathbf{y}}] - \mathbf{y}]_{1 \times m}^T [W]_{m \times m} \\ &= 2[J]_{n \times m}^T [W]_{m \times m}^T [\hat{\mathbf{y}} - \mathbf{y}]_{m \times 1} \\ &= 2[J]_{n \times m}^T [W]_{m \times m} [\hat{\mathbf{y}} - \mathbf{y}]_{m \times 1}, \end{aligned} \quad (5.37)$$

because $[W]^T = [W]$.

We start at an initial guess $\mathbf{p}$ and systematically calculate

$$\begin{aligned} [\nabla \chi^2] &= 2[J]^T [W][\hat{\mathbf{y}} - \mathbf{y}], \\ [\mathbf{h}] &= t[\nabla \chi^2] \\ [\mathbf{p}] &\leftarrow [\mathbf{p}] - [\mathbf{h}] \end{aligned}$$

until a stopping criterion is reached such as

$$|\mathbf{h}| < \epsilon.$$

Note the minus sign in the update of $\mathbf{p}$, because we are reaching for a minimum of χ^2 . The problem of course lies in what value of t to use. In some simple examples, it can be fixed at some small number. A better option (we shall see) is *backtracing line search*, which consists of changing the algorithm to

$$\begin{aligned} [\nabla \chi^2] &= 2[J]^T [W][\hat{\mathbf{y}} - \mathbf{y}], \\ t &\leftarrow 1 \\ \text{while } \chi^2(\mathbf{p} - t\nabla \chi^2) &> \chi^2(\mathbf{p}) - \frac{t}{2} |\nabla \chi^2|^2 \text{ do } t \leftarrow \beta t \\ \mathbf{h} &= t[\nabla \chi^2] \end{aligned}$$

$$\mathbf{p} \leftarrow \mathbf{p} - \mathbf{h}$$

where $\beta = 0.1$ (hardwired and constant) is the backtracing parameter, until

$$|\mathbf{h}| < \epsilon.$$

The stop criterion ϵ has a default value of 1.0×10^{-6} , and is chosen by the user by setting the variable `epsilon`. The Jacobian matrix is calculated with centered finite differences.

After the optimal set of parameters $\mathbf{p}$ is found, a set of scores is returned: the *reduced chi-square*, a standard error of estimate, and the coefficient of determination:

$$\chi_v^2 = \frac{\chi^2(\mathbf{p})}{m - n}, \quad (5.38)$$

$$\sigma_{\hat{\mathbf{y}}} = \sqrt{\frac{\chi^2(\mathbf{p})}{\sum_{i=1}^m W_{ii}}}, \quad (5.39)$$

$$r^2 = 1 - \frac{\sigma_{\hat{\mathbf{y}}}^2}{\text{wVar}\{\mathbf{y}\}}, \quad (5.40)$$

where `wVar` is the weighted variance. $\chi_v^2 \gg 1$ indicates a poor fit, $\chi_v^2 \approx 1$ indicates that the fit error is of the same order as the measurement error, and $\chi_v^2 < 1$ indicates over-fitting. When the weights are not available ($w_i = -1$), the procedure sets $w_i = 1$ internally and $\chi_v^2 \equiv 1$ (Gavin, 2022).

The parameter covariance matrix is

$$[\mathbf{V}_p] = [[\mathbf{J}]^T [\mathbf{W}] [\mathbf{J}]]^{-1} \quad (5.41)$$

and the asymptotic standard parameter error vector is

$$[\sigma_p] = \sqrt{\text{diag}([\mathbf{V}_p])} \quad (5.42)$$

(Gavin, 2022).

Capítulo 6

gnewton: Gauss-Newton (cleaner)

Two consecutive estimates of $\hat{\mathbf{y}}$ are related (to first order) by

$$\hat{\mathbf{y}}(\boldsymbol{\theta} - \mathbf{h}) = \hat{\mathbf{y}}(\boldsymbol{\theta}) - \mathbf{J} \cdot \mathbf{h}. \quad (6.1)$$

Consider two consecutive evaluations of $\chi^2(\boldsymbol{\theta})$:

$$\chi^2(\boldsymbol{\theta}) = [\hat{\mathbf{y}}(\boldsymbol{\theta}) - \mathbf{y}] \cdot \mathbf{W} \cdot [\hat{\mathbf{y}}(\boldsymbol{\theta}) - \mathbf{y}], \quad (6.2)$$

$$\chi^2(\boldsymbol{\theta} - \mathbf{h}) = [\hat{\mathbf{y}}(\boldsymbol{\theta}) - \mathbf{J} \cdot \mathbf{h} - \mathbf{y}] \cdot \mathbf{W} \cdot [\hat{\mathbf{y}}(\boldsymbol{\theta}) - \mathbf{J} \cdot \mathbf{h} - \mathbf{y}]. \quad (6.3)$$

As always, indicial notation is quicker and more clear:

$$\hat{y}_i(\theta_l - h_l) = \hat{y}_i(\theta_l) - J_{ik} h_k, \quad (6.4)$$

$$\chi^2(\theta_l) = [\hat{y}_i(\theta_l) - y_i] W_{ij} [\hat{y}_j(\theta_l) - y_j], \quad (6.5)$$

$$\chi^2(\theta_l - h_l) = [\hat{y}_i(\theta_l) - J_{ik} h_k - y_i] W_{ij} [\hat{y}_j(\theta_l) - J_{jk} h_k - y_j]. \quad (6.6)$$

Differentiating (6.6) with respect to h_k ,

$$\begin{aligned} \frac{\partial \chi^2}{\partial h_k} &= [\hat{y}_i(\theta_l) - J_{ik} h_k - y_i] W_{ij} [-J_{jk}] + [-J_{ik}] W_{ij} [\hat{y}_j(\theta_l) - J_{jk} h_k - y_j] \\ &= [\hat{y}_i(\theta_l) - J_{ik} h_k - y_i] W_{ij} [-J_{jk}] + [-J_{jk}] W_{ji} [\hat{y}_i(\theta_l) - J_{ik} h_k - y_i] \\ &= -2 [\hat{y}_i(\theta_l) - J_{ik} h_k - y_i] W_{ji} J_{jk} \\ &= -2 J_{kj}^T W_{ji} [\hat{y}_i(\theta_l) - J_{ik} h_k - y_i]. \end{aligned} \quad (6.7)$$

Because

$$\nabla_h \chi^2 = \frac{\partial \chi^2}{\partial h_k} \mathbf{e}_k, \quad (6.8)$$

we have

$$\nabla_h \chi^2 = -2 \mathbf{J}^T \cdot \mathbf{W} \cdot [\hat{\mathbf{y}}(\boldsymbol{\theta}) - \mathbf{J} \cdot \mathbf{h} - \mathbf{y}] \quad (6.9)$$

At an extremum, $\nabla_h \chi^2 = \mathbf{0}$, so that

$$\begin{aligned} -2 [\mathbf{J}]^T [\mathbf{W}] [\hat{\mathbf{y}}(\mathbf{p}) - [\mathbf{J}][\mathbf{h}] - [\mathbf{y}]] &= [\mathbf{0}], \\ [\mathbf{J}]^T [\mathbf{W}] [\mathbf{J}][\mathbf{h}] - [\mathbf{J}]^T [\mathbf{W}] [\hat{\mathbf{y}}(\mathbf{p}) - [\mathbf{y}]] &= [\mathbf{0}] \\ [\mathbf{J}]^T [\mathbf{W}] [\mathbf{J}][\mathbf{h}] &= [\mathbf{J}]^T [\mathbf{W}] [\hat{\mathbf{y}}(\mathbf{p}) - [\mathbf{y}]]. \end{aligned} \quad (6.10)$$

The Newton method now consists of starting at some value of $\boldsymbol{p}$, iterating the solution $\boldsymbol{h}$ of (6.10), and setting

$$[\boldsymbol{p}] \leftarrow [\boldsymbol{p}] - [\boldsymbol{h}]$$

until, again,

$$|\boldsymbol{h}| < \epsilon.$$

Capítulo 7

levmar: Levenberg-Marquardt

The Levenberg-Marquardt algorithm is a combination of the steepest descent and Newton methods. First, note that the update $[\mathbf{h}]$ of the steepest descent method can be written in the form

$$\begin{aligned} [\mathbf{h}] &= 2t[\mathbf{J}]^\top[\mathbf{W}][\hat{\mathbf{y}} - \mathbf{y}], \\ \lambda[\mathbf{h}] &= [\mathbf{J}]^\top[\mathbf{W}][\hat{\mathbf{y}} - \mathbf{y}] \end{aligned} \quad (7.1)$$

with $\lambda = 1/(2t)$, while the update $[\mathbf{h}]$ of the Newton method is given by (6.10). Combining both, we first have

$$([\mathbf{J}]^\top[\mathbf{W}][\mathbf{J}] + \lambda[\mathbf{I}])[\mathbf{h}] = [\mathbf{J}]^\top[\mathbf{W}][\hat{\mathbf{y}}(\mathbf{p}) - [\mathbf{y}]], \quad (7.2)$$

where $[\mathbf{I}]$ is the identity matrix. This was further modified by Marquardt (1963) and Fletcher (1971) by setting

$$D_{ij} = J_{ki}W_{kl}J_{lj}\delta_{(ij)} \quad (7.3)$$

— that is, $[\mathbf{D}]$ is a diagonal matrix formed from the diagonal elements of $[\mathbf{J}]^\top[\mathbf{W}][\mathbf{J}]$. In our implementation, $\lambda = 1$ as a starting value. We now solve for the update $[\mathbf{h}]$ and calculate ρ in each iteration as

$$([\mathbf{J}]^\top[\mathbf{W}][\mathbf{J}] + \lambda[\mathbf{D}])[\mathbf{h}] = [\mathbf{J}]^\top[\mathbf{W}][\hat{\mathbf{y}}(\mathbf{p}) - [\mathbf{y}]], \quad (7.4)$$

$$\rho = \frac{\chi^2(\mathbf{p}) - \chi^2(\mathbf{p} - \mathbf{h})}{\left| [\mathbf{h}]^\top \lambda[\mathbf{D}][\mathbf{h}] + [\mathbf{J}]^\top[\mathbf{W}][\hat{\mathbf{y}}(\mathbf{p}) - [\mathbf{y}]] \right|} \quad (7.5)$$

Now if $\rho > \epsilon_r = 1 \times 10^{-3}$, then

$$\begin{aligned} [\mathbf{p}] &\leftarrow [\mathbf{p}] - [\mathbf{h}], \\ \lambda &\leftarrow \lambda/\beta\downarrow \end{aligned}$$

otherwise,

$$\lambda \leftarrow \beta\uparrow\lambda$$

where $\beta\downarrow = 5$ and $\beta\uparrow = 2$ implement the *delayed gratification approach*. Note that β is reminiscent of, but not the same as, the backtracing parameter t of the steepest descent method.

Referências Bibliográficas

- Benjamin, J. R. e Cornell, C. A. (1970). *Probability, Statistics and Decision for Civil Engineers*. McGraw-Hill, New York.
- Fletcher, R. (1971). A modified Marquardt subroutine for non-linear least squares. Relatório técnico, Theoretical Physics Division, Atomic Energy Research Establishment Harwell, UK.
- Gavin, H. P. (2022). The Levenberg-Marquardt algorithm for nonlinear least squares curve-fitting problems. Available at <https://people.duke.edu/~hpgavin/ExperimentalSystems/lm.pdf>.
- Lambers, J. V. (2014). MAT280: Multivariable Calculus. Obtido de <https://www.math.usm.edu/lambers/mat280/> em 2023-08-04.
- Marquardt, D. W. (1963). An Algorithm for Least-Squares Estimation of Nonlinear Parameters. *Journal of the Society for Industrial and Applied Mathematics*, 11(2):pp. 431–441.
- Piskounov, N. (1969). *Differential and Integral Calculus*. MIR, Moscow.
- Strikwerda, J. C. (2004). *Finite Difference Schemes and Partial Differential Equations*. SIAM, Philadelphia, 2nd edição.